

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования

«МИРЭА – Российский технологический университет» РТУ МИРЭА

ИКБ направление «Киберразведка и противодействие угрозам с применением технологий искусственного интеллекта» 10.04.01

Кафедра КБ-4 «Интеллектуальные системы информационной безопасности»

Лабораторная работа №1

по дисциплине: «Анализ защищенности систем искусственного интеллекта»

Группа:

ББМО-01-22

Выполнил:

Гребенник Г.С

Проверил:

к.т.н. Спирин А.А.

Содержание	Co	леп	жа	ние
------------	----	-----	----	-----

	<u>-</u>
Цель	боты:

Цель работы:

Целью данной работы является отразить отличия для $fgsm_eps=(0.001, 0.02, 0.5, 0.9, 10)$ и выявить закономерность/обнаружить отсутсвие влияние параметра eps для сетей FC LeNet на датасете MNIST, NiN LeNEt на датасете CIFAR.

Ход работы:

1. Скопировать проект по ссылке в локальную среду выполнения Jupyter (Google Colab):

https://github.com/ewatson2/EEL6812_DeepFool_Project

```
[1] !git clone https://github.com/ewatson2/EEL6812_DeepFool_Project

Cloning into 'EEL6812_DeepFool_Project'...
remote: Enumerating objects: 96, done.
remote: Counting objects: 100% (3/3), done.
remote: Compressing objects: 100% (2/2), done.
remote: Total 96 (delta 2), reused 1 (delta 1), pack-reused 93
Receiving objects: 100% (96/96), 33.99 MiB | 25.90 MiB/s, done.
Resolving deltas: 100% (27/27), done.
```

2. Сменим директорию исполнения на вновь созданную папку "EEL6812 DeepFool Project" проекта:

```
%cd /content/EEL6812_DeepFool_Project
/content/EEL6812_DeepFool_Project
```

3. Импортируем библиотеки:

```
import numpy as np
import json, torch, os
from torch.utils.data import DataLoader, random_split
from torchvision import datasets, models
from torchvision.transforms import transforms
```

4. Импортируем вспомогательные библиотеки из локальных файлов проекта:

```
from models.project models import FC_500_150, LeNet_CIFAR, LeNet_MNIST, Net from utils.project utils import get_clip_bounds, evaluate_attack, display_attack
```

5. Установим случайное значение в виде переменной rand_seed=(порядковый номер в списке гугл-таблицы 11) и установим его для np.random.seed и torch.manual seed:

```
rand_seed = 11
np.random.seed(rand_seed)
torch.manual_seed(rand_seed)

torch._C.Generator at 0x787bb422e3d0>
```

6. Используем в качестсве устройства видеокарту (Среды выполнения --> Сменить среду выполнения --> T4 GPU)

```
use_cuda = torch.cuda.is_available()
device = torch.device('cuda' if use_cuda else 'cpu')
```

7. Загрузим датасет MNIST с параметрами:

```
mist_mean = 0.5
mist_std = 0.5
mist_mist_min = mist_min.to(device)
mist_min = mist_min.to(device)
mist_min = mist_min.to(device)
mist_min = mist_min.to(device)
mist_min = mist_min.to(device)
mist_tf_train = transforms.Compose([transforms.ToTensor(), transforms.ToTensor(), transforms.ToTensor(), transforms.Normalize(mean-mnist_mean, std=mnist_std)])
mist_tf_train = transforms.Compose([transforms.Normalize(mean=0.0, std=np.divide(1.0, unist_std)), transforms.Normalize(mean-np.multiply(-1.0, unist_std))]
mist_tf_inv = transforms.Compose([transforms.Normalize(mean=0.0, std=np.divide(1.0, unist_std)), transforms.Normalize(mean-np.multiply(-1.0, unist_std))]
mist_temp = datasets.NNIST(root='datasets/mist', train=True, dounload=True, transform=mmist_tf_train)
mist_test = datasets.NNIST(root='datasets/smist', train=False, dounload=True, transform=mmist_tf]

Dounloading http://yann_lecun.com/exdb/mnist/train=inases=idx3-ubyte.gz
Dounloading http://yann_lecun.com/exdb/mnist/train=inases=idx3-ubyte.gz
Dounloading http://yann_lecun.com/exdb/mnist/train=labels=idx1-ubyte.gz
Dounloading http://yann_lecun.com/exdb/mnist/train=labels=idx1-ubyte.gz
Dounloading http://yann_lecun.com/exdb/mnist/train=labels=idx1-ubyte.gz
Dounloading http://yann_lecun.com/exdb/mnist/train=labels-idx1-ubyte.gz
Dounloading http://yann_lecun.com/exdb/mnist/train=labels-idx1-ubyte.gz
Dounloading http://yann_lecun.com/exdb/mnist/train=labels-idx1-ubyte.gz
Dounloading http://yann_lecun.com/exdb/mnist/train=labels-idx1-ubyte.gz
Dounloading http://yann_lecun.com/exdb/mnist/tibk-inages=idx3-ubyte.gz
Dounloading http://yann_lecun.com/exdb/mnist/tibk-inages=idx3-ubyte.gz
Dounloading http://yann_lecun.com/exdb/mnist/tibk-inages=idx3-ubyte.gz
Dounloading http://yann_lecun.com/exdb/mnist/tibk-inages=idx3-ubyte.gz
Dounloading http://yann_lecun.com/exdb/mnist/tibk-inages=idx3-ubyte.gz
Dounloading http://yann_lecun.com/exdb/mnist/tibk-inages-idx3-ubyte.gz
Dounloading http://yann_lecun.com/exdb/mnist/tibk-inages-idx3-ubyte.gz
Dounloading http://yann_lecun.com/exdb/
```

8. Загрузим датасет CIFAR-10 с параметрами:

```
cifar_mean = [0.491, 0.482, 0.447]
cifar_star = [0.202, 0.199, 0.201]
cifar_dim = 32

cifar_min, cifar_max = get_clip_bounds(cifar_mean, cifar_std, cifar_dim)
cifar_min = cifar_min.to(device)

cifar_ff = transforms.Compose([transforms.ToTensor(), transforms.Normalize(mean-cifar_mean, std-cifar_std)])
cifar_tf = transforms.Compose([transforms.RandomCrop(size-cifar_dim, padding-4), transforms.RandomHorizontalFlip(), transforms.ToTensor(), transforms.Normalize(mean-cifar_tf_inv = transforms.Compose([transforms.Normalize(mean=[0.0.0.0, 0.0.0], std-np.divide(1.0, cifar_std)), transforms.Normalize(mean-np.multiply(-1.0, cifar_mean), std-cifar_temp = datasets.CIFAR10(root-'datasets/cifar-10', train=True, download=True, transform=cifar_tf_train)
cifar_train, cifar_val = random_split(cifar_temp, [40000])
cifar_test = datasets.CIFAR10(root-'datasets/cifar-10', train=False, download=True, transform=cifar_tf)

cifar_classes = ['airplane', 'automobile', 'bird', 'cat', 'deer', 'dog', 'frog', 'horse', 'ship', 'truck']

Downloading https://www.cs.toronto.edu/-kriz/cifar-10-python.tar.gz to datasets/cifar-10/cifar-10-python.tar.gz
Extracting datasets/cifar-10/cifar-10-python.tar.gz to datasets/cifar-10
files already downloaded and verified
```

9. Выполним настройку гиперпараметров и загрузку DataLoader:

```
batch_size = 64
workers = 4

mnist_loader_train = DataLoader(mnist_train, batch_size-batch_size, shuffle=True, num_workers=workers)
mnist_loader_val = DataLoader(mnist_test, batch_size-batch_size, shuffle=False, num_workers=workers)
mnist_loader_test = DataLoader(cifar_train, batch_size-batch_size, shuffle=False, num_workers=workers)

cifar_loader_train = DataLoader(cifar_train, batch_size-batch_size, shuffle=False, num_workers=workers)

cifar_loader_val = DataLoader(cifar_val, batch_size-batch_size, shuffle=False, num_workers=workers)

cifar_loader_test = DataLoader(cifar_test, batch_size-batch_size, shuffle=False, num_workers=workers)

cifar_loader_test = DataLoader(cifar_test, batch_size-batch_size, shuffle=False, num_workers=workers)

DataLoader_test = DataLoader(cifar_test, batch_size-batch_size, shuffle=False, num_workers=workers)

This DataLoader will create 4 worker processes in total. Our suggested max number of warnings.warn(_create_warning_msg(
```

10.Зададим параметры deep_args:

```
deep_batch_size = 10
deep_num_classes = 10
deep_overshoot = 0.02
deep_max_iters = 50

deep_args = [deep_batch_size, deep_num_classes, deep_overshoot, deep_max_iters]
```

11.Загрузим и оценим стойкость модели Network-In-Network Model к FGSM и DeepFool атакам на основе датасета CIFAR-10:

```
fgsm_eps = 0.2
model = Net().to(device)
model.load_state_dict(torch.load('weights/clean/cifar_nin.pth', map_location=torch.device('cpu')))

evaluate_attack('cifar_nin_fgsm.csv', 'results', device, model, cifar_loader_test, cifar_min, cifar_max, fgsm_eps, is_fgsm=True)
print('')
evaluate_attack('cifar_nin_deepfool.csv', 'results', device, model, cifar_loader_test, cifar_min, cifar_max, deep_args, is_fgsm=False)

if device.type == 'cuda': torch.cuda.empty_cache()

FGSM Test Error: 81.29%
FGSM Tome (All Images): 0.67 s
FGSM Time (Per Image): 67.07 us

DeepFool Time (All Images): 185.12 s
DeepFool Time (All Images): 185.12 s
DeepFool Time (Per Image): 18.51 ms
```

12.Загрузим и оценим стойкость модели LeNet к FGSM и DeepFool атакам на основе датасета CIFAR-10:

```
fgsm_eps = 0.1
model = LeNet_CIFAR().to(device)
model.load_state_dict(torch.load('weights/clean/cifar_lenet.pth', map_location=torch.device('cpu')))

evaluate_attack('cifar_lenet_fgsm.csv', 'results', device, model, cifar_loader_test, cifar_min, cifar_max, fgsm_eps, is_fgsm=True)
print('')
evaluate_attack('cifar_lenet_deepfool.csv', 'results', device, model, cifar_loader_test, cifar_min, cifar_max, deep_args, is_fgsm=False)

if device.type == 'cuda': torch.cuda.empty_cache()

FGSM Test Error : 91.71%
FGSM Robustness : 8.90e-02
FGSM Time (All Images) : 0.40 s
FGSM Time (Per Image) : 40.08 us

DeepFool Test Error : 87.81%
DeepFool Test Error : 87.81%
DeepFool Time (All Images) : 73.27 s
DeepFool Time (Per Image) : 7.33 ms
```

13. Выполним оценку атакующих примеров для сетей:

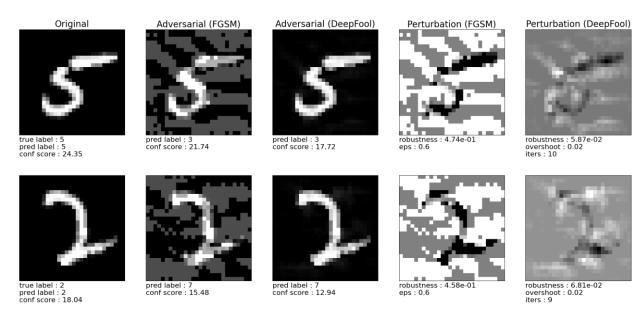
13.1. LeNet на датасет MNIST:

```
fgsm_eps = 0.6
model = LeNet_NNIST().to(device)
model.load_state_dict(torch.load('weights/clean/mmist_lenet.pth', map_location=device))

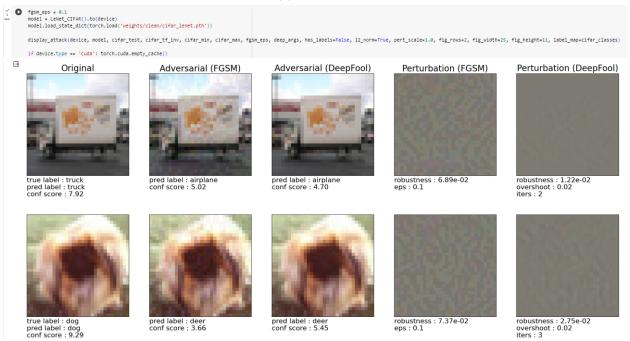
display_attack(device, model, mmist_test, mmist_tf_inv, mmist_min, mmist_max, fgsm_eps, deep_args, has_labels=False, l2_norm=True, pert_scale=1.0, fig_rows=2, fig_width=2!

if device.type == 'cuda': torch.cuda.empty_cache()

//usr/local/lib/python3.10/dist-packages/torch/utils/data/dataloader.py:557: UserWarning: This DataLoader will create 4 worker processes in total. Our suggested max number warnings.warn(_create_warning_msg(
```



13.2. LeNet на датасете CIFAR-10:

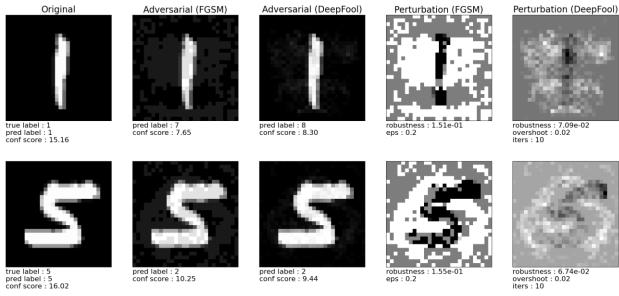


13.3. FCNet на датасете MNIST:

fgsm_eps = 0.2
model = FC_500_150().to(device)
model.load_state_dict(torch.load('weights/clean/mnist_fc.pth'))

display_attack(device, model, mnist_test, mnist_tf_inv, mnist_min, mnist_max, fgsm_eps, deep_args, has_labels=False, l2_norm=True, pert_scale=1.0, fig_rows=2, fig_width=25, fig_height=11)

if device.type == 'cuda': torch.cuda.empty_cache()



13.4. Network-in-Network на датасете CIFAR:



14.Отразим отличия для fgsm_eps=(0.001, 0.02, 0.5, 0.9, 10) и выявим закономерности/обнаружим отсутсвие влияние параметра eps для сетей FC LeNet на датасете MNIST, NiN LeNEt на датасете CIFAR: Для выполнения данной задачи реализуем просто цикл который будет перебирать уже известный нам массив значений:

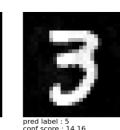




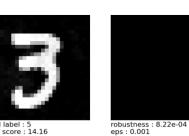


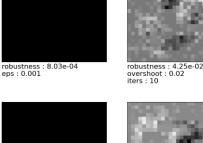
pred label : 5 conf score : 11.14

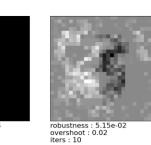
pred label : 3 conf score : 18.99



pred label : 3 conf score : 7.62







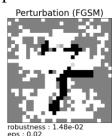
FC на MNIST при Esp 0.02 14.1.

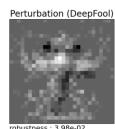


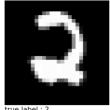


pred label : 7 conf score : 11.74



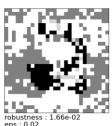


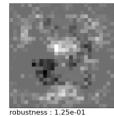






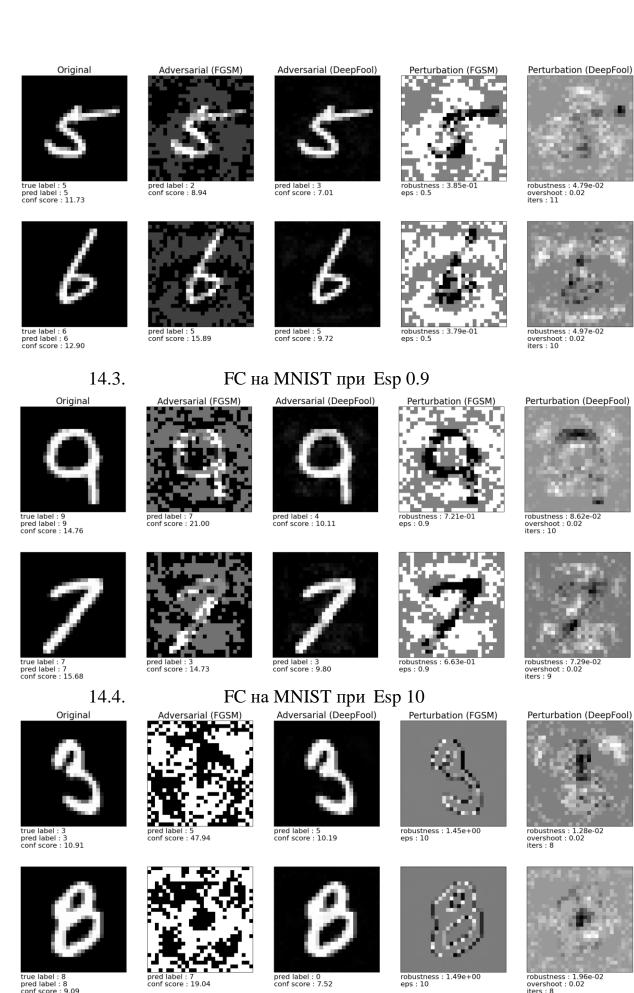






robustness: 1.25e-01 overshoot: 0.02 iters: 10

FC на MNIST при Esp 0.5 14.2.



14.2. Esp 0.001 Adversarial (FGSM) Original Adversarial (DeepFool) Perturbation (FGSM) Perturbation (DeepFool) true label : cat pred label : cat conf score : 25.50 robustness : 6.61e-04 eps : 0.001 robustness : 9.45e-03 overshoot : 0.02 iters : 3 pred label : cat conf score : 25.30 pred label : dog conf score : 20.62 robustness : 7.32e-03 overshoot : 0.02 iters : 2 true label : dog pred label : dog conf score : 21.33 robustness : 5.88e-04 eps : 0.001 14.5. Esp 0.02 Adversarial (FGSM) Adversarial (DeepFool) Original Perturbation (DeepFool) Perturbation (FGSM) true label : airplane pred label : airplane conf score : 20.30 robustness : 3.25e-02 overshoot : 0.02 iters : 2 pred label : cat conf score : 14.43 pred label : airplane conf score : 19.11 robustness: 1.05e-02 eps: 0.02



pred label : ship conf score : 27.89

true label : ship pred label : ship conf score : 31.55 pred label : truck conf score : 25.79 robustness : 2.10e-02 overshoot : 0.02 iters : 2

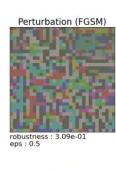
robustness: 1.39e-02 eps: 0.02



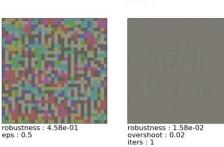


Adversarial (FGSM)













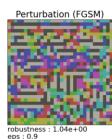


pred label : autom conf score : 21.94



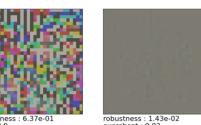
pred label : truck conf score : 37.31













true label : automobile pred label : automobile conf score : 42.11

pred label : truck conf score : 20.41



pred label : truck conf score : 36.35

Adversarial (DeepFool)

robustness: 6.37e-01 eps: 0.9

Perturbation (FGSM)

robustness: 1.43e-02 overshoot: 0.02 iters: 1

Perturbation (DeepFool)

14.8. Esp 10





pred label : autom conf score : 22.81



pred label : bird conf score : 27.62

robustness : 2.90e+00 eps : 10

robustness : 3.07e-02 overshoot : 0.02 iters : 2



true label : horse pred label : horse conf score : 48.69

12

Заключение

При рассмотрении результатов эксперимента, проведенного в рамках данной лабораторий работы, была выявлена закономерность, обозначающая, что при увеличении значения ерѕ, сети становятся более уязвимыми и допускают больше ошибок классификации, нежели при низком значении ерѕ.